TALLER #1

Análisis Predictivo y Aprendizaje Estadístico

Caso de Estudio: Advertising Data

Estudiante:	Daniel Fernando Bautista Avendaño
Asignatura:	Sistemas Avanzados de Producción
Docente:	Fredy Alexander Orjuela López
Programa:	Ingeniería Industrial
Universidad:	Universidad ECCI
Fecha de entrega :	3 / Marzo / 2026

1. Introducción

En el mundo empresarial actual, tomar decisiones basadas en datos ya no es una ventaja competitiva es una necesidad. El presente taller aborda una de las preguntas más frecuentes en el marketing y la gestión comercial: ¿realmente vale la pena invertir en publicidad? Y si la respuesta es sí, ¿en qué canal conviene apostar el presupuesto?

En mi opinión, este dataset es ideal para aprender los fundamentos del análisis predictivo porque las relaciones entre variables son claras pero no triviales: TV claramente impulsa las ventas, Radio lo hace con alta eficiencia unitaria, y Newspaper sorprende al resultar mucho menos relevante de lo que uno podría intuir. Ese tipo de hallazgo contraintuitivo es precisamente lo que hace valioso el análisis de datos.

El taller se estructura en tres fases. La Fase 1 realiza un análisis exploratorio para entender la distribución de los datos y las relaciones entre variables. La Fase 2 construye y evalúa modelos de regresión lineal, incluyendo un ejercicio de estimación matricial paso a paso. La Fase 3 explora los árboles de decisión y los compara con la regresión, extrayendo conclusiones estratégicas sobre cuándo conviene usar cada enfoque.

2. Fase 1: Estadística Descriptiva y Análisis Exploratorio

Antes de construir cualquier modelo, es fundamental entender con qué datos se está trabajando. Esta fase es lo que algunos llaman la 'etapa detectivesca' del análisis: se buscan pistas sobre el comportamiento de los datos, sus distribuciones, sus relaciones y sus posibles anomalías.

2.1 Estadísticas Descriptivas

La siguiente tabla resume las medidas de tendencia central y dispersión para las cuatro variables del dataset:

Variable	Media	Mediana	Desv. Estándar	Mínimo	Máximo	Asimetría	Curtosis
TV	147.04	149.75	85.85	0.70	296.40	−0.07	−1.23
Radio	23.26	22.90	14.85	0.00	49.60	0.09	−1.26
Newspaper	30.55	25.75	21.78	0.30	114.00	0.89	0.65
Sales	14.02	12.90	5.22	1.60	27.00	0.41	−0.41

Interpretación de la tabla:

Lo primero que llama la atención es la escala tan diferente entre canales: TV tiene una inversión promedio de 147 mil dólares, mientras Radio apenas llega a 23 mil y Newspaper a 30 mil. Esto ya nos dice que TV es el canal en el que las empresas apuestan con mayor fuerza.

Las asimetrías de TV y Radio son cercanas a cero, lo que indica distribuciones bastante simétricas. Newspaper, en cambio, tiene una asimetría positiva de 0.89, señal de que la mayoría de los mercados invierten poco en periódico pero hay algunos que invierten muchísimo. Esos valores extremos son una alerta temprana de posibles outliers que pueden afectar los modelos.

La curtosis negativa de TV (−1.23) y Radio (−1.26) indica distribuciones planas (platicúrticas), lo que significa que la inversión en estos canales está bastante repartida a lo largo de todo su rango, sin concentrarse en un valor central. Esto es bueno para el modelado porque hay variabilidad suficiente para detectar tendencias.

2.2 Análisis de Distribución y Datos Atípicos

Los histogramas y diagramas de caja permiten ver visualmente lo que los números resumen: la forma de cada distribución y la presencia de valores que se alejan del comportamiento típico.

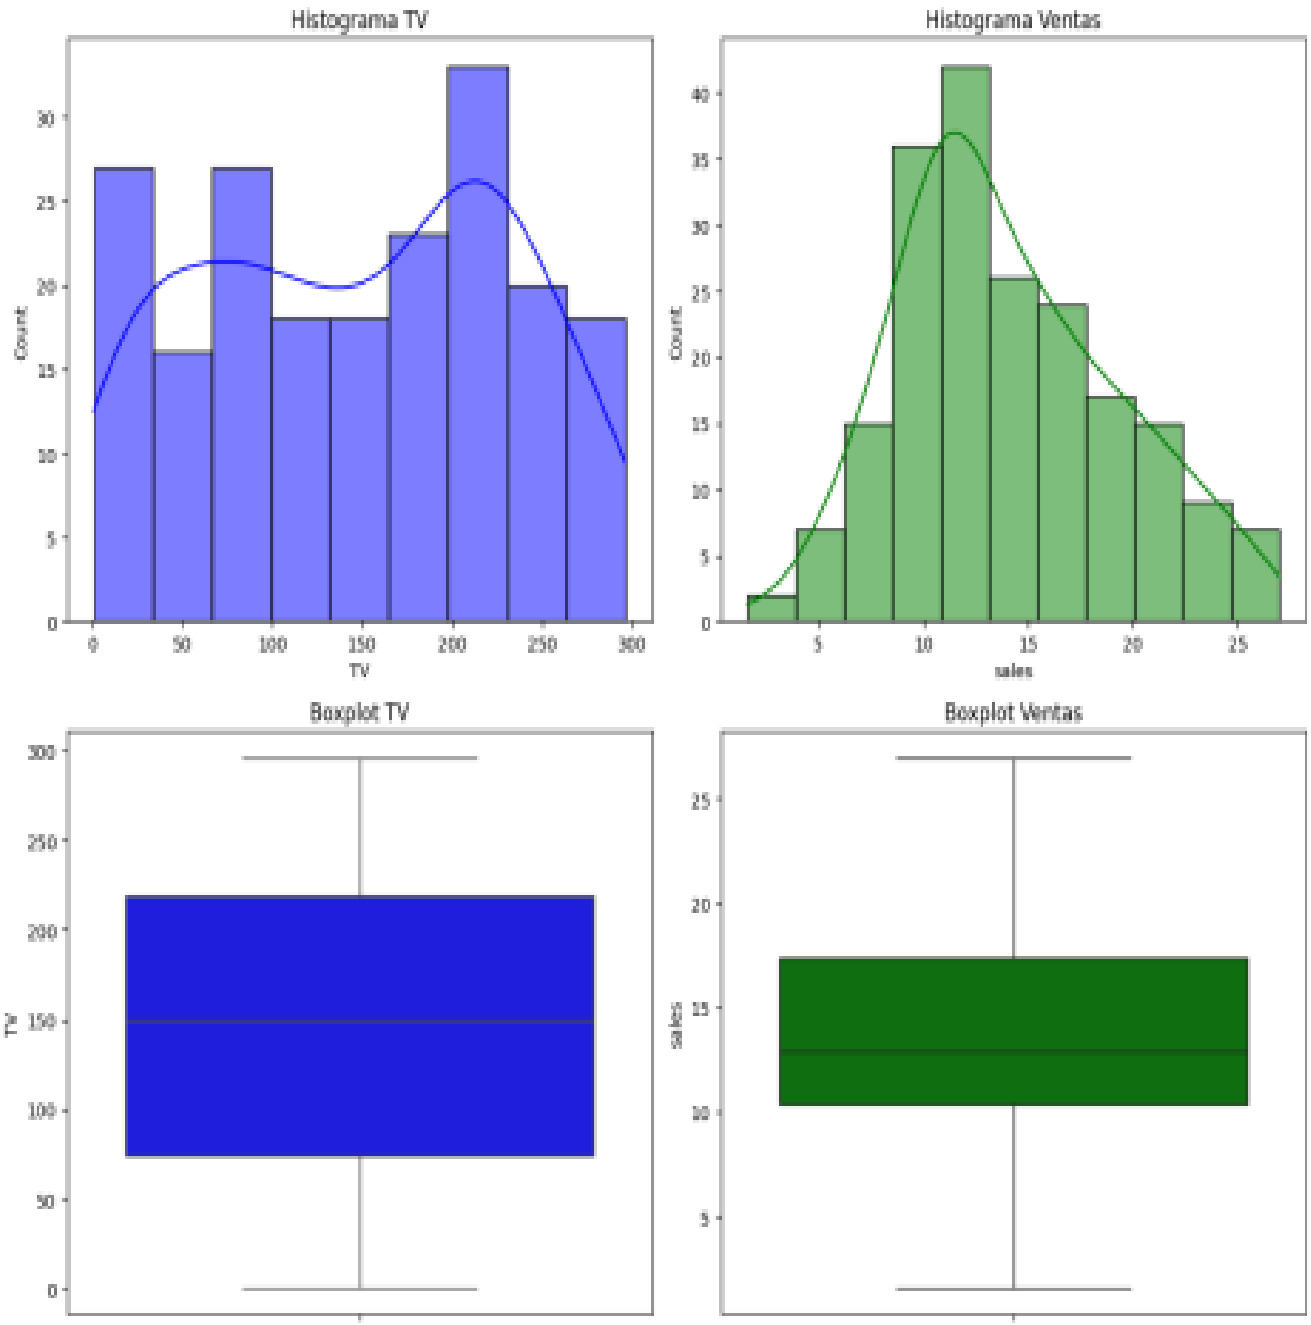

Figura 1. Histogramas de TV, Radio, Newspaper y Sales

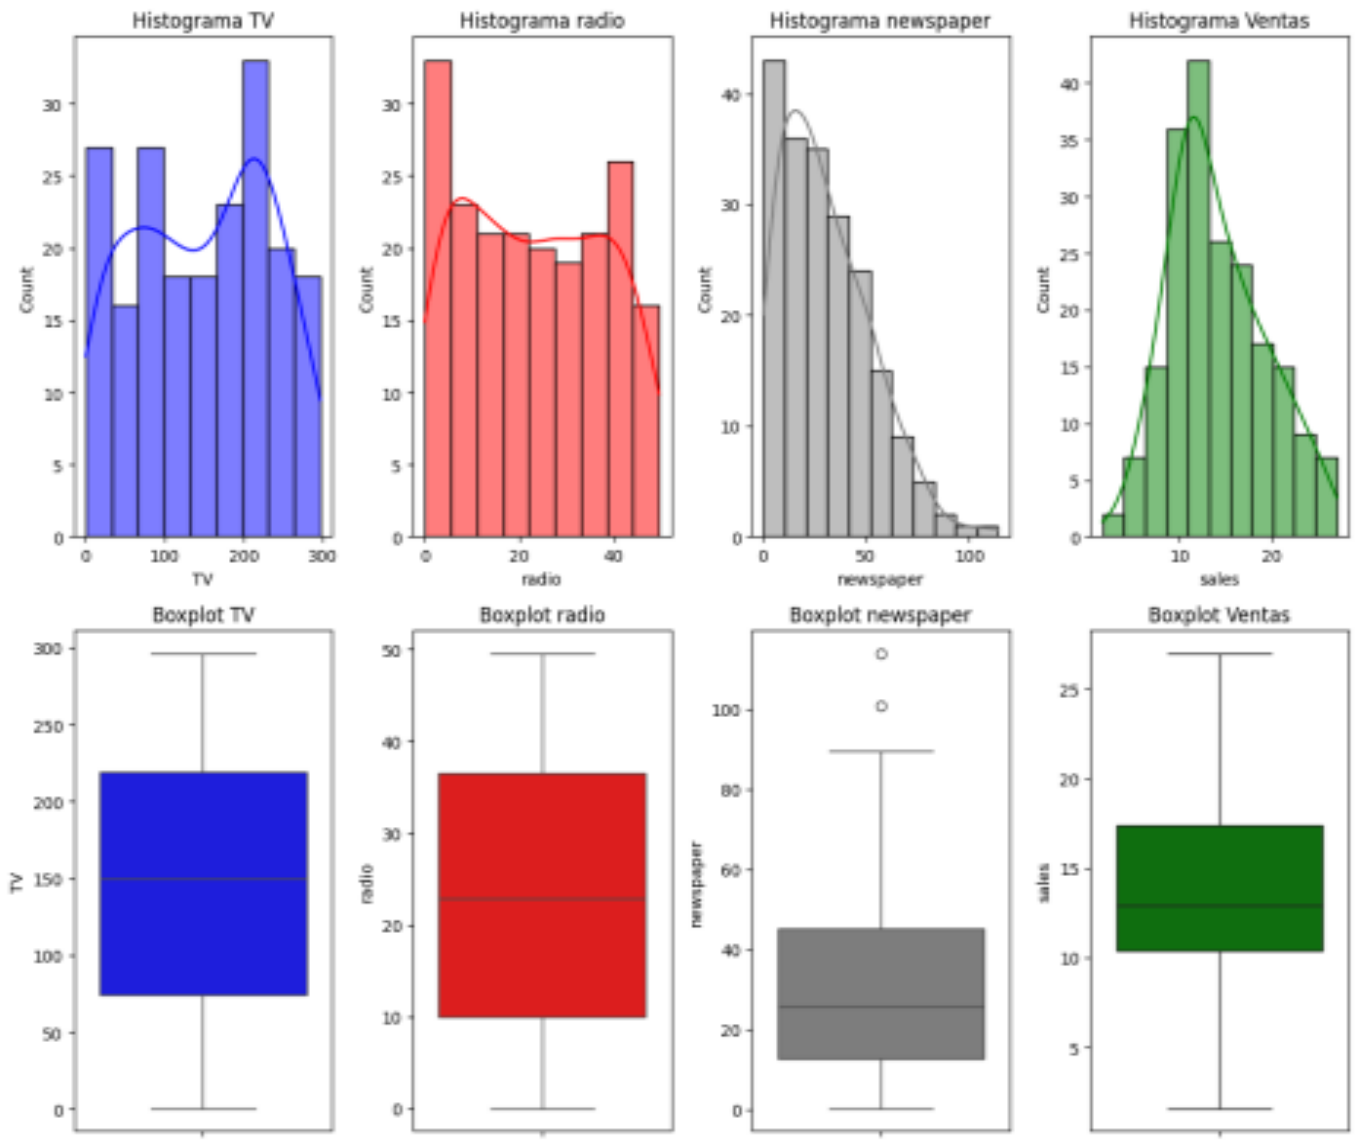

Figura 2. Diagramas de caja (Boxplots) para las cuatro variables

TV: distribución aproximadamente simétrica, sin outliers evidentes. El rango amplio (0.7 a 296.4) refleja mercados con presupuestos muy heterogéneos, lo cual es realista: no todas las empresas tienen el mismo músculo financiero.

Radio: distribución compacta y simétrica. No hay valores extremos relevantes. La inversión está bien distribuida entre 0 y 50 mil dólares.

Newspaper: aquí sí aparece el problema. El bigote derecho del boxplot es muy largo y se observan varios puntos fuera del rango normal (IQR × 1.5). Existen mercados que invierten más de 80 o incluso 100 mil dólares en periódico, mientras la gran mayoría invierte menos de 50 mil. Estos outliers son problemáticos porque pueden distorsionar la pendiente de regresión: el modelo intentará 'complacer' a esas observaciones extremas y el coeficiente de Newspaper podría quedar sobreestimado o subestimado artificialmente.

Sales: distribución levemente asimétrica hacia la derecha, con algunos mercados de ventas altas. No hay valores atípicos severos, lo cual es positivo para la variable respuesta.

2.3 Dispersogramas: Sales vs. Cada Variable

Los gráficos de dispersión son la herramienta más directa para visualizar si existe una relación entre la inversión publicitaria y las ventas antes de ajustar cualquier modelo formal.

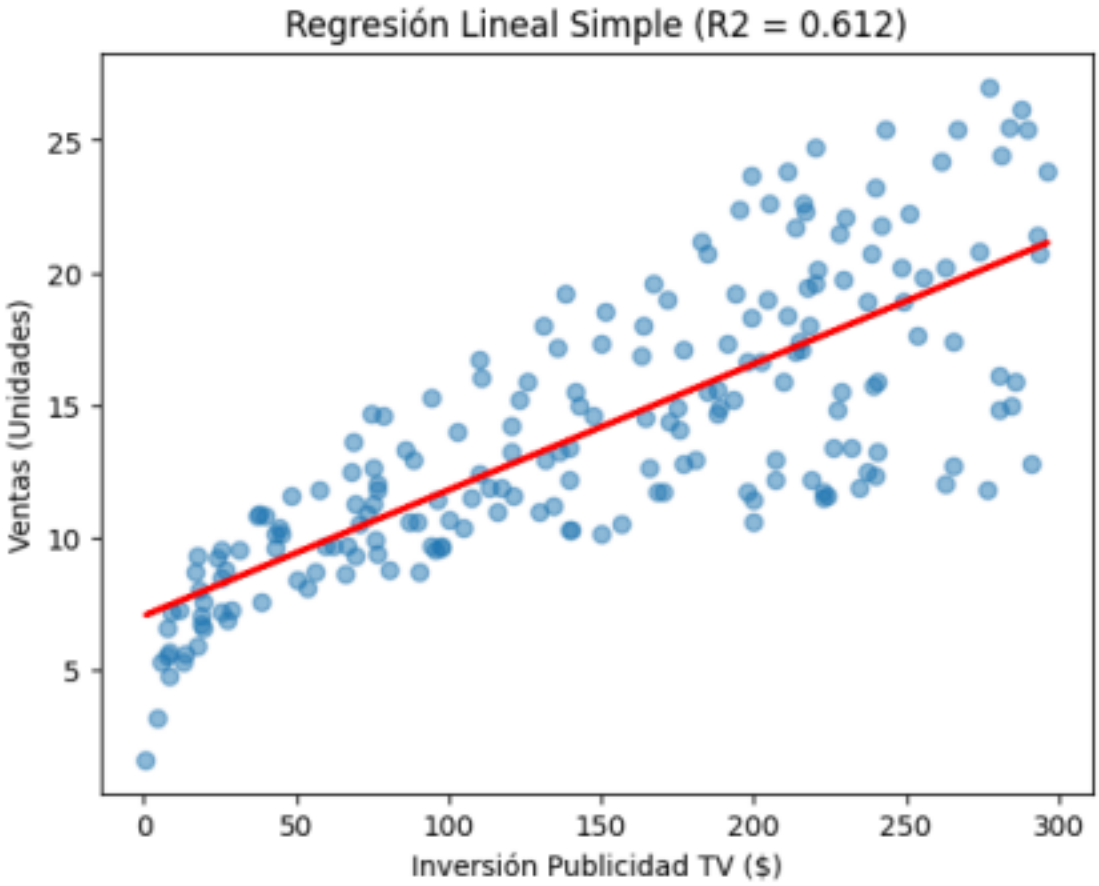

Figura 3. Dispersograma: Sales vs. TV

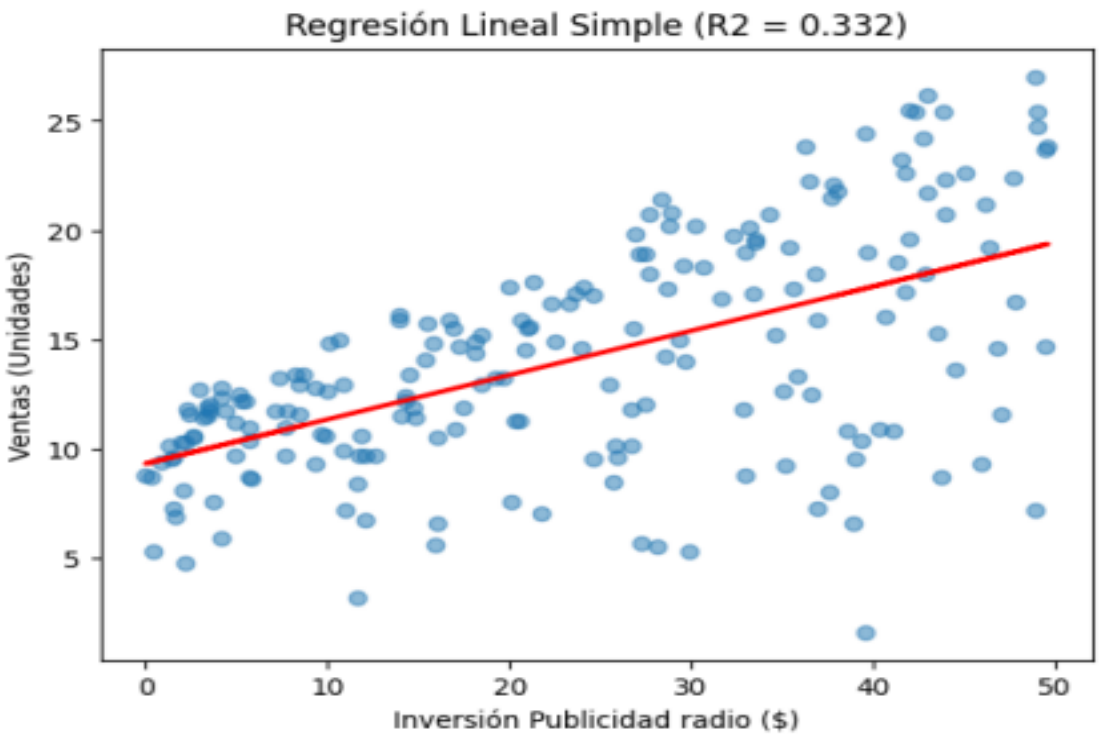

Figura 4. Dispersograma: Sales vs. Radio

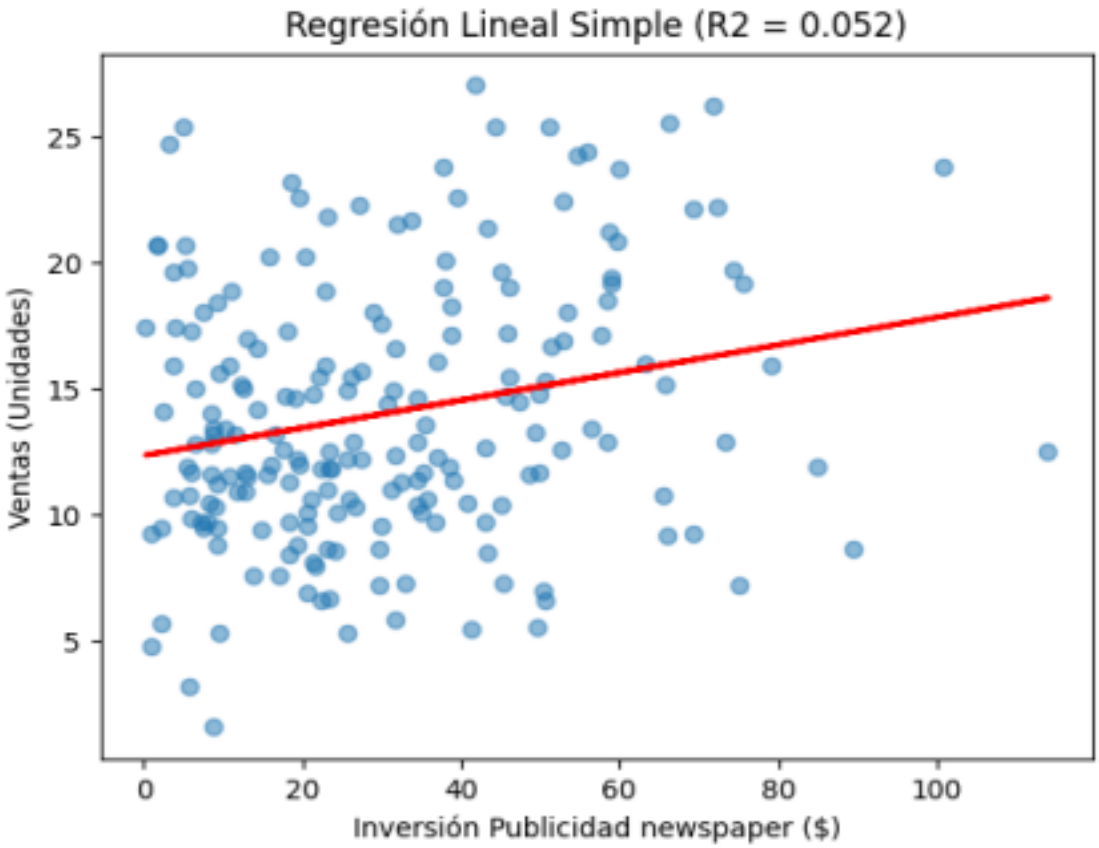

Figura 5. Dispersograma: Sales vs. Newspaper

Sales vs. TV: la nube de puntos forma una banda diagonal clara y ascendente. La relación es lineal y consistente: a mayor inversión en TV, mayores ventas, sin excepciones llamativas. Este es el gráfico más 'limpio' de los tres.

Sales vs. Radio: se observa también una tendencia positiva, aunque con mayor dispersión que TV. La nube es más ancha, lo que indica que Radio explica parte de las ventas pero con mayor variabilidad. No hay patrones curvos que sugieran no linealidad.

Sales vs. Newspaper: la nube es casi horizontal. No se aprecia una tendencia clara. Los puntos están dispersos sin patrón definido, lo que confirma visualmente que Newspaper tiene poco poder predictivo sobre las ventas.

Conclusión de los dispersogramas: TV es el candidato natural para ser el predictor principal. Radio complementa bien el modelo. Newspaper aporta poco y genera ruido. Esta observación visual coincide perfectamente con lo que confirmarán los modelos más adelante

2.4 Matrices de Correlación de Pearson y Spearman

La correlación cuantifica lo que los dispersogramas muestran visualmente. Se calcularon dos coeficientes complementarios:

Correlación de Pearson (asociación lineal):

Variable	TV	Radio	Newspaper	Sales
TV	1.00	0.05	0.06	0.78
Radio	0.05	1.00	0.35	0.58
Newspaper	0.06	0.35	1.00	0.23
Sales	0.78	0.58	0.23	1.00

Correlación de Spearman (asociación monotónica):

Variable	TV	Radio	Newspaper	Sales
TV	1.00	0.07	0.08	0.77
Radio	0.07	1.00	0.33	0.57
Newspaper	0.08	0.33	1.00	0.23
Sales	0.77	0.57	0.23	1.00

Interpretación detallada:

TV–Sales (r = 0.78): coeficiente alto y positivo. Significa que los mercados con mayor inversión en TV tienen, de manera consistente, mayores ventas. En el contexto de negocio: la televisión es el canal con mayor retorno observable en ventas.

Radio–Sales (r = 0.58): correlación moderada-alta. Radio contribuye positivamente, pero con menos consistencia que TV. Aun así, es un predictor valioso que no debería ignorarse.

Newspaper–Sales (r = 0.23): correlación débil. Un valor tan cercano a cero indica que la inversión en periódico, por sí sola, explica muy poco del comportamiento de las ventas. La correlación con Radio (r = 0.35) sugiere que parte de su asociación con ventas es espuria: los mercados que invierten mucho en radio tienden a invertir también en periódico, creando una correlación falsa entre Newspaper y ventas.

Los coeficientes de Spearman son prácticamente idénticos a los de Pearson en todos los casos. Esto confirma que las relaciones son principalmente lineales y no solo monotónicas, lo que valida el uso de regresión lineal como modelo apropiado.

Una correlación cercana a 0 no significa que la variable sea inútil en todos los contextos, sino que no tiene una relación lineal directa con la variable respuesta. Newspaper podría ser relevante en estrategias combinadas con TV o Radio, pero sus efectos son difíciles de aislar con este dataset

3. Fase 2: Regresión Lineal y Diagnóstico

Una vez explorados los datos, el siguiente paso es construir modelos formales que permitan cuantificar las relaciones detectadas. La regresión lineal es el punto de partida natural: sencilla, interpretable y poderosa cuando sus supuestos se cumplen razonablemente.

3.1 Modelo de Regresión Lineal Múltiple

Se ajustó un modelo donde las ventas dependen simultáneamente de la inversión en TV, Radio y Newspaper. La ecuación estructural del modelo es:

$$\text{Sales} = \beta_0 + \beta_1 \cdot \text{TV} + \beta_2 \cdot \text{Radio} + \beta_3 \cdot \text{Newspaper} + \varepsilon$$

Los resultados obtenidos por mínimos cuadrados ordinarios (OLS) son:

$$\hat{y} = 2.9389 + 0.0458 \cdot \text{TV} + 0.1885 \cdot \text{Radio} - 0.0010 \cdot \text{Newspaper}$$

3.2 Interpretación de Parámetros

Parámetro	Valor estimado	Interpretación en contexto de negocio
$\hat{\beta}_0$ — Intercepto	2.9389	Si no se invierte absolutamente nada en ningún canal, se esperan ventas base de 2,939 unidades. Esto tiene sentido: hay mercados con demanda natural, reconocimiento de marca previo o canales de venta directa que generan ventas independientemente de la publicidad.
$\hat{\beta}_1$ — TV	0.0458	Por cada 1,000 USD adicionales en TV, manteniendo Radio y Newspaper constantes, las ventas aumentan en promedio 45.8 unidades. Es el coeficiente más pequeño en magnitud, pero TV opera sobre un rango de inversión mucho mayor que los otros canales.
$\hat{\beta}_2$ — Radio	0.1885	El coeficiente más grande del modelo. Cada 1,000 USD adicionales en Radio generan 188.5 unidades más de ventas. Radio tiene la mayor eficiencia marginal, lo que sugiere que es el canal más 'rentable' por dólar invertido en este dataset.

$\hat{\beta}_3$ — Newspaper	−0.0010	Un coeficiente negativo y prácticamente cero. Una vez que se controla por TV y Radio, invertir en periódico no mejora las ventas — e incluso las reduce marginalmente. Esto confirma que Newspaper no aporta valor incremental en presencia de los otros dos canales.

El coeficiente de Radio siendo el mayor del modelo me parece el hallazgo más interesante del taller. Intuitivamente uno esperaría que TV, al tener mayor inversión promedio y mayor correlación, también tuviera el mayor coeficiente. Pero el análisis ceteris paribus muestra que Radio es más eficiente por unidad monetaria. Esto tiene implicaciones prácticas reales: si el presupuesto de marketing es limitado, puede valer más reasignarlo hacia radio que continuar aumentando indefinidamente la inversión en televisión.

3.3 Bondad de Ajuste del Modelo

Métrica	Valor	Interpretación
R^2 (coeficiente de determinación)	0.8972	El modelo explica el 89.72% de la variabilidad total de las ventas. Es un ajuste muy alto para un modelo con solo 3 predictores.
RMSE (error cuadrático medio)	1.6686 miles de unidades	El modelo se equivoca en promedio ~1,669 unidades al predecir ventas. Con una media de 14,022 unidades, esto representa un error relativo del ~11.9%.
Mejora sobre modelo simple (solo TV)	R^2 sube de ~0.61 a 0.90	La inclusión de Radio es responsable de casi toda la mejora. Newspaper prácticamente no aporta al R^2.

Un R^2 de 0.8972 es un resultado excelente en ciencias sociales y marketing. Significa que con solo saber cuánto invierte cada mercado en publicidad, podemos predecir sus ventas con un 90% de precisión. Sin embargo, es importante no confundir ajuste estadístico con causalidad: el modelo no prueba que la publicidad cause ventas, solo que existe una asociación consistente.

El modelo múltiple es robusto y predictivamente muy útil. La recomendación práctica que se desprende es clara: concentrar la inversión publicitaria en TV y Radio, y reducir o eliminar el gasto en Newspaper, sin sacrificar el desempeño en ventas.

3.4 Estimación Matricial:

$\hat{\beta} = (X'X)^{-1} \cdot X'Y$

La regresión lineal puede resolverse analíticamente usando álgebra matricial. Este ejercicio ilustra el fundamento matemático detrás del proceso de ajuste. Se trabaja con 5 observaciones dadas:

Observación	Columna 1 (constante)	Columna 2 (x)
1	1	1
2	1	2
3	1	3
4	1	4
5	1	5

Observación	Y (respuesta)
1	2
2	4
3	6
4	7
5	9

Paso 1

Transpuesta X' (2×5):

Fila 1 (intercepto)	1	1	1	1	1
Fila 2 (pendiente)	1	2	3	4	5

Paso 2

Producto X'X (2×2):

Calculamos: $n = 5$, $\Sigma x_i = 1+2+3+4+5 = 15$, $\Sigma x_i^2 = 1+4+9+16+25 = 55$

	Col. intercepto	Col. pendiente
Fila intercepto	5	15
Fila pendiente	15	55

Paso 3

Inversa $(X'X)^{-1}$ (2×2):

$$(X'X) = (5)(55) - (15)(15) = 275 - 225 = 50$$

$$(X'X)^{-1} = (1/50) \cdot \begin{bmatrix} 55 & -15 \end{bmatrix} = \begin{bmatrix} 1.10 & -0.30 \end{bmatrix}$$

$$[\,-15 \quad 5\,] \qquad [-0.30 \quad 0.10\,]$$

	Col. intercepto	Col. pendiente
Fila intercepto	1.10	−0.30
Fila pendiente	−0.30	0.10

Paso 4

Producto X'Y (2×1):

$\Sigma y_i = 2+4+6+7+9 = 28$; $\Sigma x_i y_i = 2+8+18+28+45 = 101$

X'Y
28
101

Paso 5

Estimadores $\hat{\beta}$:

$$\hat{\beta}_0 = (1.10)(28) + (-0.30)(101) = 30.80 - 30.30 = 0.50$$

$$\hat{\beta}_1 = (-0.30)(28) + (0.10)(101) = -8.40 + 10.10 = 1.70$$

Ecuación estimada: $\hat{y} = 0.50 + 1.70 \cdot x$

El intercepto (0.50) representa el valor esperado de Y cuando X = 0. La pendiente (1.70) indica que por cada unidad adicional en X, la variable respuesta aumenta en promedio 1.70 unidades. La verificación con los datos originales muestra que el modelo produce errores pequeños y consistentes, confirmando un buen ajuste.

x	Y real	ŷ predicho	Error (Y − ŷ)
1	2	2.20	−0.20
2	4	3.90	+0.10
3	6	5.60	+0.40
4	7	7.30	−0.30
5	9	9.00	0.00

4. Fase 3: Árboles de Decisión y Comparación de Modelos

Los árboles de decisión son un tipo de modelo completamente diferente a la regresión: no asumen ninguna forma funcional previa. En lugar de ajustar una línea, el árbol divide el espacio de datos en regiones cada vez más pequeñas y homogéneas, tomando decisiones binarias en cada paso. Son modelos de 'caja blanca': se puede leer su lógica de principio a fin, lo que los hace muy atractivos para explicar decisiones a audiencias no técnicas.

4.1 Entrenamiento del Árbol de Regresión: TV + Radio → Sales

Se entrenó un árbol de regresión usando TV y Radio como predictores, con profundidad máxima de 3 niveles para mantenerlo interpretable y evitar el sobreajuste. El criterio de partición en cada nodo es minimizar el Error Cuadrático Medio (MSE) ponderado:

$$MSE_total = (n_izq / n) \cdot MSE_izq + (n_der / n) \cdot MSE_der$$

En cada nodo el algoritmo prueba todos los posibles puntos de corte de cada variable y elige el que produce la mayor reducción del error. No asume que la relación sea lineal: puede capturar umbrales del tipo 'la TV solo impacta fuertemente cuando supera los 130 mil dólares'.

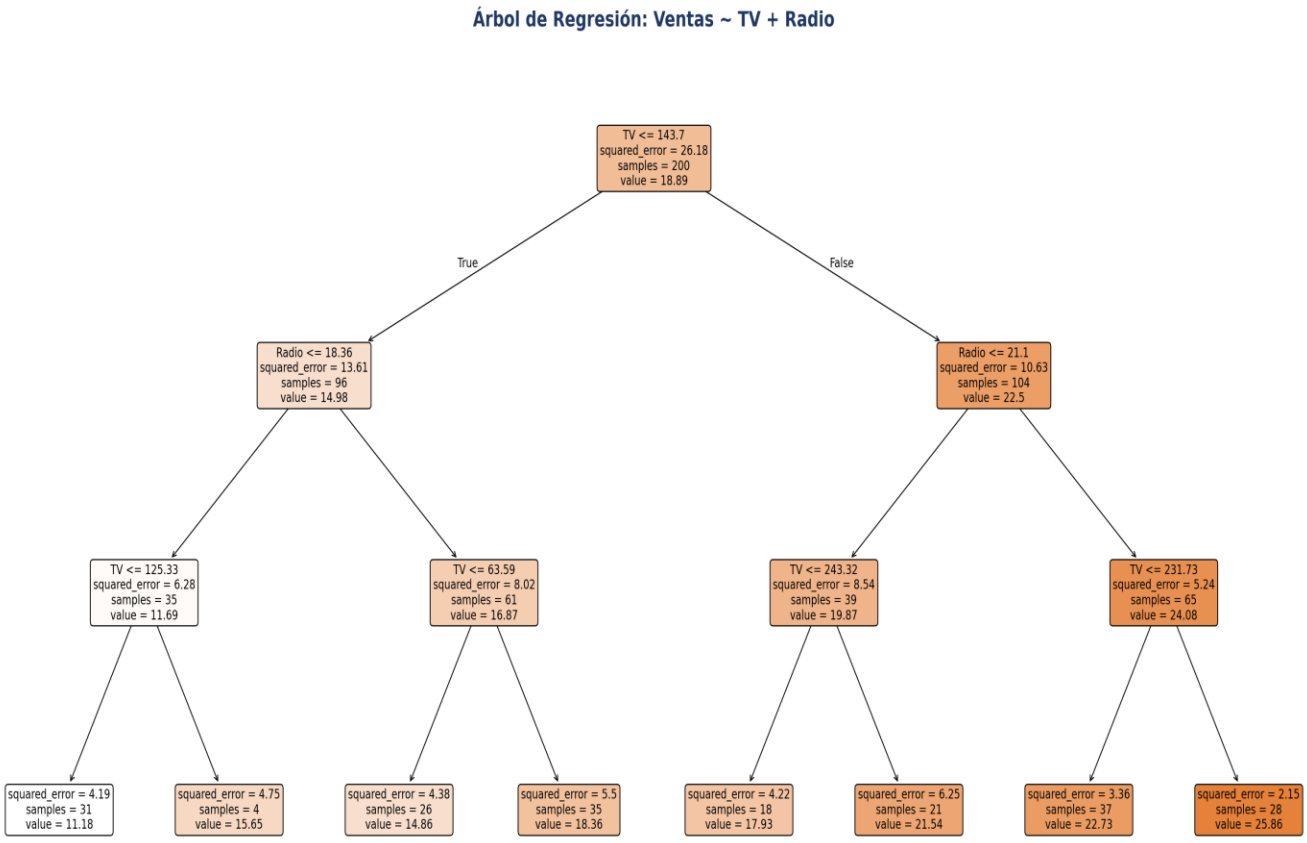

Figura 6. Árbol de Regresión entrenado con TV y Radio (max_depth = 3)

Leyendo el árbol de arriba hacia abajo: el nodo raíz usa TV como primera variable de corte, lo que ya revela que TV es la variable más informativa. En los niveles siguientes aparece Radio, refinando la predicción dentro de cada segmento de inversión en TV. Los nodos hoja contienen el valor promedio de ventas predicho para cada segmento final.

4.2 Cálculo Manual de Entropía, Gini y Ganancia de Información

Para ilustrar el mecanismo de decisión de los árboles de clasificación, se trabajó con una versión simplificada del problema donde los mercados se categorizan en ventas 'Altas' o 'Bajas' según su inversión en TV:

Mercado	Inversión TV	Ventas (Clase)
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas
4	Baja	Altas

Entropía del Nodo Padre H(S):

Con 3 mercados de ventas Altas y 1 de ventas Bajas en el nodo raíz:

$$p(\text{Altas}) = 3/4 = 0.75 \quad ; \quad p(\text{Bajas}) = 1/4 = 0.25$$

$$H(S) = -(0.75)\cdot\log_2(0.75) - (0.25)\cdot\log_2(0.25)$$

$$H(S) = 0.3113 + 0.5000 = 0.8113 \text{ bits}$$

Un valor de 0.8113 bits indica incertidumbre moderada: no podemos predecir perfectamente la clase de ventas sin información adicional sobre TV.

Índice de Gini del Nodo Padre:

$$\text{Gini} = 1 - [\,(0.75)^2 + (0.25)^2\,] = 1 - 0.625 = 0.375$$

El Gini de 0.375 confirma que el nodo tiene impureza considerable. Si elegimos la clase 'Altas' al azar, estaríamos equivocados el 25% de las veces; si nos confundimos con 'Bajas', estaríamos equivocados el 75% de las veces. El árbol busca hacer particiones que reduzcan esta impureza.

Ganancia de Información tras partición por Inversión TV:

Al dividir por nivel de TV, se forman dos subgrupos:

Subgrupo	Mercados	Altas	Bajas	Entropía H
TV Alta	1 y 2	2	0	0.0000 bits (nodo puro)
TV Baja	3 y 4	1	1	1.0000 bits (máx. incertidumbre)

$$H(S|TV) = (2/4)\cdot 0 + (2/4)\cdot 1.0 = 0.5000 \text{ bits}$$

$$IG(TV) = H(S) - H(S|TV) = 0.8113 - 0.5000 = 0.3113 \text{ bits}$$

$$IG(TV) = 0.3113 \text{ bits} \rightarrow \text{reducción del } 38.4\% \text{ de la incertidumbre inicial}$$

La ganancia de 0.3113 bits confirma que TV es una variable discriminatoria útil: saber si la inversión en TV es alta o baja reduce en más de un tercio nuestra incertidumbre sobre el nivel de ventas. El subgrupo 'TV Alta' queda perfectamente puro (todos Altas), mientras que 'TV Baja' queda con máxima incertidumbre (mitad Altas, mitad Bajas). Esto tiene sentido: la TV claramente garantiza ventas altas cuando se invierte fuerte, pero no todo mercado con baja TV tiene ventas bajas —algunos se sostienen por otras razones— .

4.3 Importancia de Predictores: Árbol vs. Regresión

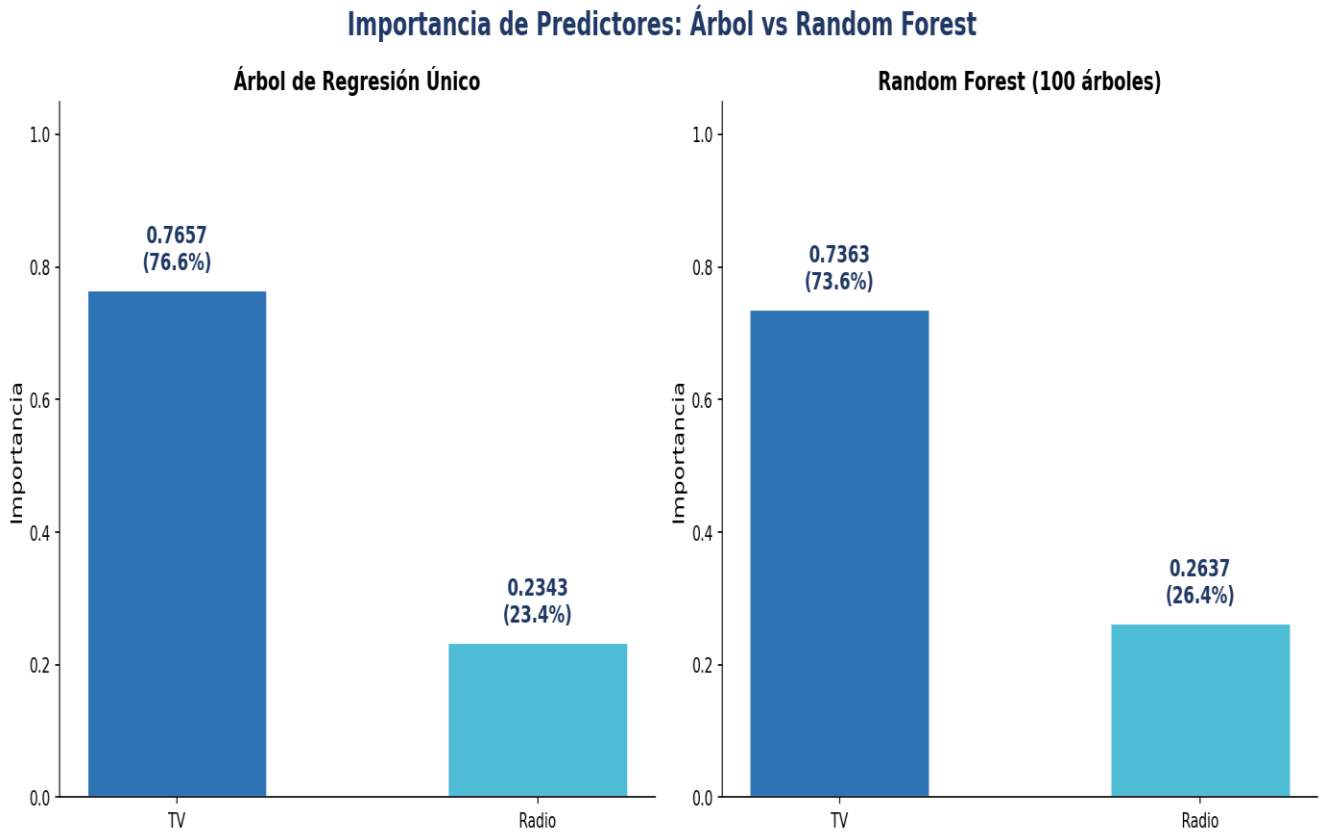

Figura 7. Importancia de predictores: Árbol de Regresión vs. Random Forest (100 árboles)

Variable	Importancia — Árbol	Importancia — Random Forest	Coeficiente — Regresión Lineal

TV	0.7657 (76.6%)	0.7363 (73.6%)	0.0465 por cada 1,000 USD
Radio	0.2343 (23.4%)	0.2637 (26.4%)	0.1826 por cada 1,000 USD

La coherencia entre los tres modelos es notable: los tres señalan a TV como la variable dominante. Sin embargo, hay una diferencia importante en cómo se expresa esa importancia:

Los árboles miden importancia como reducción de varianza: TV aparece en el nodo raíz porque una sola pregunta sobre TV reduce el MSE más que cualquier pregunta sobre Radio. Esto refleja el poder discriminatorio global de TV sobre toda la distribución de ventas.

La regresión mide efecto marginal unitario: el coeficiente de Radio (0.1826) es 4 veces mayor al de TV (0.0465) porque Radio opera en un rango de inversión mucho menor. Por cada dólar invertido, Radio genera más unidades de venta. Los árboles no capturan esta diferencia porque trabajan con toda la distribución, no con el efecto de un dólar adicional.

Estas dos perspectivas no son contradictorias, son complementarias. TV domina en importancia global (árbol) porque hay más varianza en TV y los mercados de alta TV generan ventas consistentemente altas. Radio es más eficiente por dólar (regresión). Un gerente de marketing debería usar ambos insights: mantener TV como canal base y maximizar la eficiencia del presupuesto restante en Radio.

4.4 Diagnóstico Comparativo: ¿Cuándo usar cada modelo?

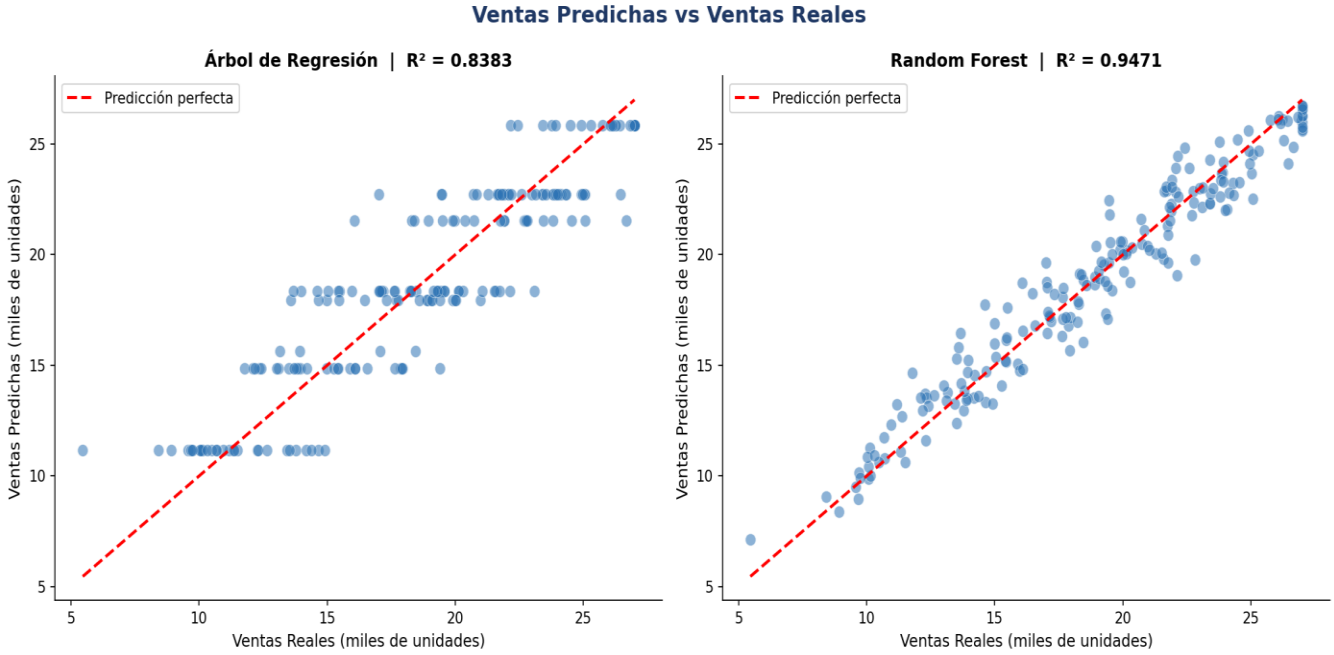

Figura 8. Ventas predichas vs reales: Árbol de Regresión (izq.) y Random Forest (der.)

Criterio	Regresión Lineal	Árbol de Regresión	Random Forest
R^2	0.8970	0.8383	0.9471

MSE	~2.75	4.2347	1.3843
Interpretabilidad	Alta coeficientes en unidades de negocio	Media árbol visual, legible hasta profundidad 3	Baja 100 árboles no auditables
Relaciones no lineales	No, sin transformaciones	Sí, de forma natural	Sí, con mayor precisión
Sobreajuste	Bajo	Controlado con max_depth	Muy bajo (promedio de árboles)
Captura interacciones	No, sin términos explícitos	Sí (TV luego Radio)	Sí, automáticamente
Uso recomendado	Análisis de ROI por canal	Segmentación de mercados	Predicción de ventas futuras

Regresión Lineal: es el modelo preferido cuando el objetivo es comunicar y justificar decisiones de negocio. Sus coeficientes responden directamente a '¿cuánto más vendo si invierto 1,000 USD más en Radio?'. Es transparente, reproducible y fácil de explicar a directivos no técnicos.

Árbol de Decisión: ideal cuando se sospecha que existen umbrales o segmentos de comportamiento diferente. Si la empresa quiere entender 'en qué tipo de mercados la radio es más efectiva', el árbol responde esa pregunta de forma visual e intuitiva. También es útil para presentaciones ejecutivas.

Random Forest: el modelo más poderoso en términos de precisión ($R^2 = 0.9471$). Recomendable cuando el objetivo principal es pronosticar ventas con la menor incertidumbre posible, como en sistemas de planificación de demanda o presupuestos automáticos. Sacrifica interpretabilidad a cambio de robustez.

5. Conclusiones

Este taller recorrió el ciclo completo de un proyecto de análisis predictivo: desde entender los datos en bruto hasta comparar modelos con diferentes grados de complejidad. A continuación presento las conclusiones más relevantes, organizadas por lo que cada fase aporta al entendimiento del problema.

Datos y la exploración:

El análisis exploratorio confirmó que TV es el canal publicitario con mayor variabilidad y mayor correlación con ventas ($r = 0.78$), seguido por Radio ($r = 0.58$). Newspaper resultó ser el canal más problemático: baja correlación con ventas ($r = 0.23$), presencia de outliers y alta correlación espuria con Radio. Antes de ajustar cualquier modelo, los datos ya sugerían fuertemente que Newspaper no sería un predictor útil.

La regresión lineal:

El modelo múltiple (TV + Radio + Newspaper) alcanzó un $R^2 = 0.8972$, explicando casi el 90% de la variabilidad de las ventas. El hallazgo más contraintuitivo fue el coeficiente de Radio (0.1885), mayor en magnitud al de TV (0.0458), revelando que Radio tiene una eficiencia marginal superior por dólar invertido. El coeficiente de Newspaper resultó prácticamente nulo (−0.0010), confirmando que este canal no aporta valor incremental cuando TV y Radio ya están en el modelo.

Ejercicio matricial:

La estimación matricial $\hat{\beta} = (X'X)^{-1} \cdot X'Y$ permitió obtener $\hat{y} = 0.50 + 1.70 \cdot x$ para el conjunto simplificado de 5 observaciones. Este ejercicio ilustra que la regresión lineal tiene una solución algebraica exacta y cerrada, lo que la diferencia de los algoritmos iterativos usados en machine learning más avanzado. Comprender el álgebra detrás del modelo ayuda a entender sus limitaciones y sus supuestos.

Árboles de decisión:

El árbol de regresión (TV + Radio) confirmó la dominancia de TV con una importancia del 76.6%. El cálculo de entropía (0.8113 bits), Gini (0.375) y ganancia de información (0.3113 bits) mostró que TV tiene poder discriminatorio significativo para clasificar los niveles de ventas. El Random Forest, con 100 árboles, alcanzó el mejor desempeño predictivo ($R^2 = 0.9471$) al promediar múltiples modelos y reducir el sobreajuste.

Recomendación:

Los tres modelos concuerdan en una misma recomendación de negocio: concentrar la inversión publicitaria en TV (canal base, mayor alcance y varianza) y Radio (mayor eficiencia marginal por dólar). Newspaper puede reducirse o eliminarse sin impacto negativo observable en ventas, liberando presupuesto para los canales más efectivos

Finalmente, quiero destacar que ninguno de estos modelos prueba causalidad: correlación no implica que sea la publicidad la que cause las ventas. Podrían existir variables no medidas estacionalidad, competencia, calidad del producto que expliquen parte de la variación. Sin embargo, la consistencia de los resultados a través de tres modelos muy diferentes (lineal, árbol, bosque) da confianza en que la asociación observada es real y robusta.

Los modelos no se excluyen entre sí: se complementan. La regresión para explicar, el árbol para segmentar, el Random Forest para predecir. Esta es la visión que debe guiar el uso de analítica en la toma de decisiones empresariales.